

SPRINT 3

Modelagem Linear para Aprendizado de Máquina

Análise de Distribuição Normal e Regressão Linear

Integrante	RM
André Balan Felix dos Santos	571691
Davi Sinhorini Pacheco	569487
Gabriel Da Silva Silveira	568910
Henrique De Souza Aragão	570529
João Vitor Jun Nishiye de Souza	572079

Turma: 1CCPQ

Variável aleatória analisada: Temperatura Média (°F)

1. Introdução

Este relatório aplica estatística e aprendizado de máquina a uma base meteorológica de Melbourne, Flórida. Conforme o enunciado, a variável numérica escolhida é considerada normalmente distribuída. Para a regressão, Temperatura Mínima é X e Temperatura Média é Y.

Após o tratamento dos dados, foram utilizadas 1.794 observações válidas.

2. Base de dados e tratamento

A base final é entregue em Excel (.xlsx), com uma aba de identificação da equipe e outra com os dados ('Base de Dados'). O código lê o arquivo diretamente nesse formato (`pandas.read_excel`), converte as colunas numéricas, remove valores ausentes e elimina códigos inválidos de temperatura média (valores menores ou iguais a -90).

Medida	Resultado
Observações válidas	1794
Média	74.2681 °F
Mediana	76.0000 °F
Desvio padrão amostral	8.6652 °F

3. Item 01 — Probabilidade acima da Mediana

a) Mediana

A mediana da Temperatura Média é **76.00 °F**.

b) Probabilidade

Considerando $X \sim N(\mu, s)$, $\mu = 74.2681$ °F e $s = 8.6652$ °F:

$$Z = (76.00 - 74.2681) / 8.6652 = 0.1999$$


$$P(X > 76.00) = 42.0792\%.$$

c) Código e resultado

O código utiliza `scipy.stats.norm.sf()` para calcular a cauda superior da distribuição normal.

d) Classificação

Com **42.08%**, o evento é classificado como **Pouco provável**, utilizando a régua explicitada neste relatório (0–25% raro; 25–50% pouco provável; 50–75% provável; 75–100% quase certo).



4. Item 02 — Probabilidade dentro do intervalo (média $\pm 2s$)

a) Média, desvio padrão e intervalo

Média = 74.2681 °F; desvio padrão = 8.6652 °F.

Intervalo: [56.9377, 91.5985] °F.

b) Probabilidade


$P(\mu - 2s \leq X \leq \mu + 2s) = 95.4500\%$.

c) Código e resultado

O cálculo utiliza `norm.cdf()` nos limites inferior e superior.

d) Classificação

Com 95.45%, o evento é **Quase certo** pela régua adotada.




5. Item 03 — Modelagem com Regressão Linear

a) Código

Foi utilizada a regressão linear simples do scikit-learn, com Temperatura Mínima como X e Temperatura Média como Y.

$$Y = 19.6185 + 0.8256X$$

b) Gráfico



c) Interpretação

O coeficiente angular 0.8256 indica que um aumento de 1 °F na Temperatura Mínima está associado a um aumento médio estimado de aproximadamente 0.83 °F na Temperatura Média. O intercepto 19.6185 representa a estimativa de Y quando X = 0 °F. A correlação é $r = 0.9687$ e $R^2 = 0.9384$ (93.84%), indicando relação linear positiva muito forte e elevada capacidade explicativa no conjunto analisado.

6. Organização, clareza e interpretação geral

A estatística descritiva fornece medidas centrais e de dispersão; a distribuição normal permite calcular as probabilidades solicitadas; e a regressão linear modela a relação entre duas variáveis. Em aprendizado de máquina, a regressão é um método supervisionado porque os coeficientes são aprendidos a partir de dados com variável resposta conhecida.

7. Conclusão

Os três itens foram atendidos com cálculos reproduzíveis em Python. Resultados: mediana = 76.00 °F; $P(X > \text{mediana}) = 42.08\%$; intervalo $\mu \pm 2s = [56.94, 91.60]$ °F; $P(\text{intervalo}) = 95.45\%$; regressão $Y = 19.6185 + 0.8256X$; $R^2 = 0.9384$.

8. Código-fonte completo

Arquivo: `analise_modelagem_linear.py` — lê a base diretamente em `base_dados_modelagem_FINAL.xlsx` (aba 'Base de Dados'), sem dependência de arquivos intermediários em `.csv`.

```
# =====
# SPRINT 3 - MODELAGEM LINEAR PARA APRENDIZADO DE MÁQUINA
# Análise de Distribuição Normal e Regressão Linear
#
# Integrantes:
# André Balan Felix dos Santos - RM 571691
# Davi Sinhorini Pacheco - RM 569487
# Gabriel Da Silva Silveira - RM 568910
# Henrique De Souza Aragão - RM 570529
# João Vitor Jun Nishiye de Souza - RM 572079
#
# Turma: 1CCPQ
# =====

from pathlib import Path
import pandas as pd
import numpy as np
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from scipy.stats import norm
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# -----
# 1. LEITURA E TRATAMENTO DA BASE
# -----
PASTA = Path(__file__).resolve().parent
ARQUIVO = PASTA / "base_dados_modelagem_FINAL.xlsx"

if not ARQUIVO.exists():
    raise FileNotFoundError(
        f"Arquivo não encontrado: {ARQUIVO}\n"
        "Coloque 'base_dados_modelagem_FINAL.xlsx' na mesma pasta deste arquivo .py."
    )

df = pd.read_excel(ARQUIVO, sheet_name="Base de Dados")
df.columns = df.columns.str.strip()

COLUNAS = ["MIN TEMP", "MAX TEMP", "MEAN TEMP"]
for coluna in COLUNAS:
    df[coluna] = pd.to_numeric(df[coluna], errors="coerce")

# Remove valores ausentes e códigos inválidos de temperatura média.
df = df[df["MEAN TEMP"] > -90].dropna(subset=COLUNAS).copy()

if len(df) < 2:
    raise ValueError("A base não possui observações suficientes após o tratamento.")

temperatura = df["MEAN TEMP"]

# -----
# 2. ESTATÍSTICA DESCRITIVA
# -----
media = temperatura.mean()
mediana = temperatura.median()
desvio_padrao = temperatura.std(ddof=1)

print("=" * 70)
print("ANÁLISE ESTATÍSTICA - TEMPERATURA MÉDIA")
print("=" * 70)
print(f"Observações válidas: {len(df)}")
print(f"Média: {media:.4f} °F")
print(f"Mediana: {mediana:.4f} °F")
print(f"Desvio padrão amostral: {desvio_padrao:.4f} °F")

# -----
# 3. ITEM 01 - PROBABILIDADE ACIMA DA MEDIANA
```

```

# -----
z_mediana = (mediana - media) / desvio_padrao
prob_acima_mediana = norm.sf(mediana, loc=media, scale=desvio_padrao)

def classificar(p):
    if p <= 0.25:
        return "Raro"
    if p <= 0.50:
        return "Pouco provável"
    if p <= 0.75:
        return "Provável"
    return "Quase certo"

print("\n" + "=" * 70)
print("01) PROBABILIDADE DE TEMPERATURA ACIMA DA MEDIANA")
print("=" * 70)
print(f"Mediana: {mediana:.4f} °F")
print(f"Z da mediana: {z_mediana:.4f}")
print(f"P(X > {mediana:.2f}) = {prob_acima_mediana:.4%}")
print(f"Classificação: {classificar(prob_acima_mediana)}")

# -----
# 4. ITEM 02 - PROBABILIDADE DENTRO DE MÉDIA ± 2s
# -----
limite_inferior = media - 2 * desvio_padrao
limite_superior = media + 2 * desvio_padrao

prob_intervalo = (
    norm.cdf(limite_superior, loc=media, scale=desvio_padrao)
    - norm.cdf(limite_inferior, loc=media, scale=desvio_padrao)
)

print("\n" + "=" * 70)
print("02) PROBABILIDADE DENTRO DO INTERVALO MÉDIA ± 2s")
print("=" * 70)
print(f"Média: {media:.4f} °F")
print(f"Desvio padrão: {desvio_padrao:.4f} °F")
print(f"Limite inferior: {limite_inferior:.4f} °F")
print(f"Limite superior: {limite_superior:.4f} °F")
print(f"P({limite_inferior:.2f} <= X <= {limite_superior:.2f}) = {prob_intervalo:.4%}")
print(f"Classificação: {classificar(prob_intervalo)}")

# -----
# 5. ITEM 03 - REGRESSÃO LINEAR
# -----
X = df[["MIN TEMP"]]
y = df[["MEAN TEMP"]]

modelo = LinearRegression()
modelo.fit(X, y)

intercepto = float(modelo.intercept_)
coeficiente = float(modelo.coef_[0])
previsoes = modelo.predict(X)
r2 = r2_score(y, previsoes)
correlacao = np.corrcoef(df[["MIN TEMP"], y])[0, 1]

print("\n" + "=" * 70)
print("03) REGRESSÃO LINEAR")
print("=" * 70)
print("Variável X: Temperatura Mínima (°F)")
print("Variável Y: Temperatura Média (°F)")
print(f"Equação: Y = {intercepto:.4f} + {coeficiente:.4f}X")
print(f"Coeficiente angular (b1): {coeficiente:.4f}")
print(f"Intercepto (b0): {intercepto:.4f}")
print(f"Correlação de Pearson (r): {correlacao:.4f}")
print(f"Coeficiente de determinação (R²): {r2:.4f} ({r2:.2%})")

# -----
# 6. GRÁFICOS
# -----
x_grid = np.linspace(
    temperatura.min() - 4 * desvio_padrao,
    temperatura.max() + 4 * desvio_padrao,
    500
)

plt.figure(figsize=(9, 5))

```

```

plt.hist(temperatura, bins=20, density=True, alpha=0.65, label="Dados observados")
plt.plot(x_grid, norm.pdf(x_grid, media, desvio_padrao), linewidth=2, label="Normal ajustada")
plt.axvline(media, linestyle="--", linewidth=2, label=f"Mediana = {media:.2f} °F")
plt.title("Distribuição da Temperatura Média e Normal Ajustada")
plt.xlabel("Temperatura Média (°F)")
plt.ylabel("Densidade")
plt.legend()
plt.tight_layout()
plt.savefig(PASTA / "grafico_distribuicao_normal.png", dpi=180)
plt.close()

plt.figure(figsize=(9, 5))
plt.hist(temperatura, bins=20, density=True, alpha=0.65, label="Dados observados")
plt.plot(x_grid, norm.pdf(x_grid, media, desvio_padrao), linewidth=2, label="Distribuição Normal")
plt.axvspan(limite_inferior, limite_superior, alpha=0.22, label="Intervalo  $\mu \pm 2s$ ")
plt.axvline(media, linestyle="--", linewidth=2, label=f"Média = {media:.2f} °F")
plt.title("Probabilidade dentro do intervalo Média  $\pm 2s$ ")
plt.xlabel("Temperatura Média (°F)")
plt.ylabel("Densidade")
plt.legend(fontsize=8)
plt.tight_layout()
plt.savefig(PASTA / "grafico_intervalo_2s.png", dpi=180)
plt.close()

plt.figure(figsize=(9, 5))
plt.scatter(df["MIN TEMP"], y, s=16, alpha=0.5, label="Observações")
xs = np.linspace(df["MIN TEMP"].min(), df["MIN TEMP"].max(), 200).reshape(-1, 1)
xs_df = pd.DataFrame(xs, columns=["MIN TEMP"])
plt.plot(xs_df["MIN TEMP"], modelo.predict(xs_df), linewidth=2, label="Reta de regressão linear")
plt.title("Regressão Linear: Temperatura Mínima  $\times$  Temperatura Média")
plt.xlabel("Temperatura Mínima (°F)")
plt.ylabel("Temperatura Média (°F)")
plt.legend()
plt.tight_layout()
plt.savefig(PASTA / "grafico_regressao_linear.png", dpi=180)
plt.close()

# -----
# 7. RESUMO FINAL
# -----
print("\n" + "=" * 70)
print("RESUMO DOS RESULTADOS")
print("=" * 70)
print(f"01)  $P(X > \text{mediana}) = \{\text{prob\_acima\_mediana:.4}\} \rightarrow \{\text{classificar}(\text{prob\_acima\_mediana})\}$ ")
print(f"02)  $P(\mu - 2s \leq X \leq \mu + 2s) = \{\text{prob\_intervalo:.4}\} \rightarrow \{\text{classificar}(\text{prob\_intervalo})\}$ ")
print(f"03)  $R^2$  da regressão =  $\{r^2:.4f\} \rightarrow$  relação linear muito forte")
print("=" * 70)

```

9. Referências

ALURA. Estatística com Python: Correlação e Regressão. Conteúdo de apoio indicado no enunciado.

ALURA. Cálculo da probabilidade da distribuição normal com quaisquer valores de média e desvio padrão. Fórum Alura, 2022. Conteúdo de apoio indicado no enunciado.